S.O. T4: Sistemas de ficheros

1. Introducción

1.1. Fundamentos

-Un **sistema** de **ficheros** es la **capa** del **Sistema Operativo** que **gestiona** el **espacio** de **dispositivos** de **bloques** como los **discos**, organizándolos en **volúmenes**, **particiones**, **directorios**, **ficheros**, …

-¿Qué **aporta** un **sistema** de **ficheros**?:

- **Almacenamiento** de **cantidades ingentes** de **datos**.
- **Persistencia** de la **información** cuando **finaliza** el **proceso** que la **creó**.
- **Intercambio** de **información** entre **usuarios**.
- **Acceso concurrente** a la **información** desde **múltiples procesos**.
- **Fiabilidad** de la **información almacenada** y **tolerancia** a **fallos**.
- **Niveles** de **seguridad** para **proteger** la **información**.

1.2. Fichero

-**Concepto**: **Secuencia** de **bytes** alojados en **disco** y **visibles** al **usuario**, **organizados** en un **espacio lógico secuencial**.

-**Tipos**: El **formato** o la **estructura** impuesta de un **fichero** suele venir **reflejado** en su **extensión** o **sufijo**. Ejemplos:

Extensión	Significado
.bak	Copia de seguridad o *backup*
.c	Programa fuente en lenguaje C
.o	Fichero objeto (salida del compilador, aún no enlazado)
.gif	Imagen en formato GIF (Graphical Interchange Format)
.html	Página Web en formato HTML (HyperText Markup Language)
.pdf	Documento en formato PDF (Portable Document Format)
.zip	Fichero comprimido
.txt	Fichero de texto

1.3. Atributos del fichero

-Constituyen **información adicional** que el **sistema operativo mantiene** para cada **fichero**: **Metadatos** (datos acerca de los datos). Ejemplos:

Atributo	Significado
Protección	Quién tiene permisos para acceder a un fichero y de qué manera
Propietario	Usuario al que pertenece el fichero
Tamaño	Número de bytes que contiene
Fecha de creación	Día y hora en que fue creado el fichero
Último acceso	Día y hora en que fue accedido por última vez
Último modificación	Día y hora en que cambiaron sus contenidos por última vez

2. Tecnologías de almacenamiento masivo

2.1. Tecnología magnética

-Es la del **disco duro tradicional**.

-**Modelos** más **populares**:

- Barracuda de Seagate.
- Blue/Green de Western Digital (WD).

-La **información** se **organiza** en **tres planos**:

- Vertical: Cilindros y platos (platters).
- Horizontal: Pistas (tracks).
- Circular: Sectores (de 4 Kbytes en UNIX).

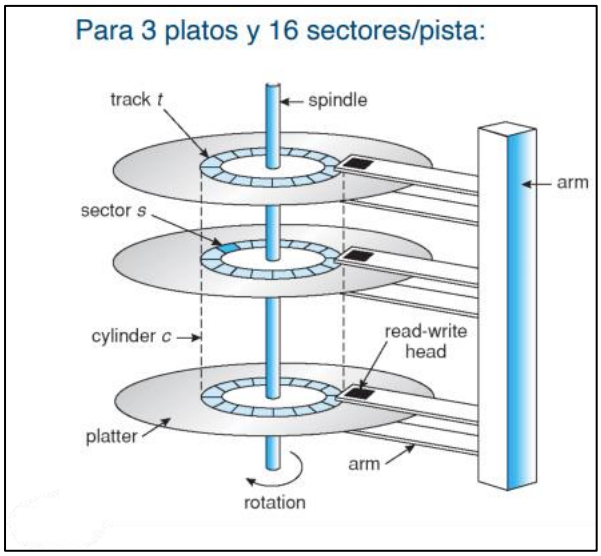

-La **unidad mínima** de **almacenamiento** es el **cluster**, que agrupa **sectores** para **amortizar latencia** con el **ancho** de **banda**.

2.2. Detalles internos de un disco duro SCSI de Western Digital

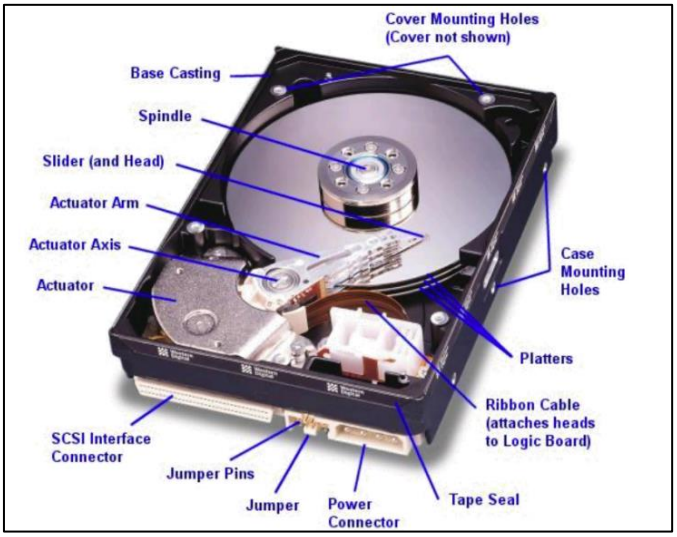

2.3. Parámetros de funcionalidad y rendimiento

-**Capacidad** en **Terabytes** (240 bytes): Aprox. 1 billón de bytes.

-**Latencia**: Tiempo de acceso al primer sector.

-**Principal causa** de su **lentitud** (1-5 ms.) por el **posicionamiento mecánico**. Vista la **geometría** del **disco**, sumaríamos 3 tiempos:

- Latencia vertical. El **brazo** mueve **2 cabezales por plat**o (envés/revés) a la **vez**, por lo que no **necesita desplazarse verticalmente**, ahorrando este tiempo.

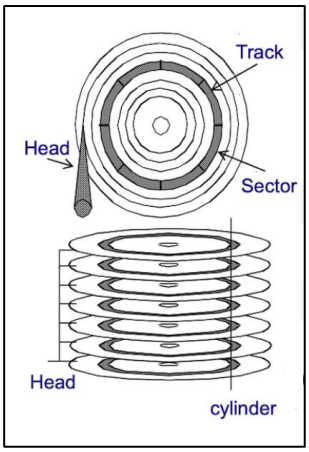

- Latencia horizontal (*seek time*). **Tiempo** para **ubicarse** en la **pista circular**.
- Latencia rotacional (*rotational latency*). **Tiempo** para que el **primer sector pase** bajo el **cabezal**. Para un disco de 10.000 RPM, será un máximo de:
  - El disco da 10.000 vueltas cada 60 s. = 166.66 vueltas/sg. = tarda 1/166.66 s. en completar una vuelta, que son 6 ms. de latencia rotacional máxima (y 3 ms. de media).

-**Ancho de banda (*transfer rate*):** Es el **ritmo** al que **envía datos** al PC. En la **memoria** lo veíamos como **bandwidth**.

- Si rota a 10.000 RPM y posee 128 sectores de 8 KB. en cada pista, el disco recorre una pista de 128x8KB=1MB en 6 milisegundos: 1 MB / 6 ms = 166.66 MB/s.

2.4. Análisis de rendimiento del disco

-Para **leer** o **escribir** en el **disco**, entran en juego **3 tiempos**:

- Latencia horizontal (seek time), para el posicionamiento en la pista.
- Latencia rotacional (rotational latency), o espera hasta que el sector deseado pase bajo el cabezal.
- Tiempo de transferencia, en función del ancho de banda del disco.

-Ejemplo: Para el disco anterior de 10.000 RPM, sectores de 8 KB y 128 sectores por pista, donde ya calculamos:

- Latencia rotacional media (3 ms.) y ancho de banda (166 MB/s.).
- Si tenemos un seek time típico de 5 ms. y queremos leer un fichero de 1 MB cuyos sectores se guardan todos consecutivos en disco, tardaríamos:
  - Time = Seek + Rotational + Transfer = 5 ms. + 3 ms. + (1 MB / 166 MB/s.) = 5 ms. + 3 ms. + 0.006 s. = 14 ms.

2.5. Direccionamiento a disco

-El **sector 0** corresponde a la **pista más externa** del **cabezal más superior**. A partir de ahí, para **posicionarnos** en un **sector** del disco son necesarias **3 coordenadas**:

- **Número de cabezal**: Hay dos cabezales por plato y entre 2 y 4 platos, para un máximo de 8 cabezales en total.
- **Número de cilindro**: Hay miles de ellos, y si el cabezal ya viene dado, en realidad este número determina la pista.
- **Número de sector**: Suele haber 64-128 sectores por pista. Se utiliza un factor de compensación para equilibrar pistas externas e internas.

- Ejemplo: Calcular la capacidad de un disco que tiene 8 cabezales, 51.200 cilindros, 128 sectores/pista y sectores de 8 Kbytes.
  - Capacidad = 8 x 51.200 x 128 x 8 Kbytes = 400 Gbytes.

2.6. Otras propiedades del disco

-Es **preciso distinguir** entre el **controlador** del **host** que **dialoga** por el **bus** con el **controlador hardware** del **disco**, y el **controlador software** o **driver** del **disco**, que se **encarga** de **configurar** el **dispositivo** y **transmitir** las **instrucciones** al **HW**.

-La **conexión** del **disco** al **host** puede ser:

- Para servidores: Fibre Channel ha reemplazado a SCSI.
- Para PCs: USB y SATA-1,2,3 han reemplazado a EIDE.

-El **formato** determina el **área** que **ocupa**, y puede ser:

- 5,25 pulgadas para los discos más viejos.
- 3,5 pulgadas para los discos más recientes.
- 2,5 pulgadas para los discos de los equipos portátiles.

-El **disco posee** una **caché** o **buffer interno** de unos **64 MB**.

2.7. Tecnología de estado sólido

-Basada en matrices de celdas, al igual que DRAM y Flash.

-Frente a la tecnología magnética:

- +++ Mucho más fiable, al no tener:
  - Partes móviles.
  - Componentes mecánicos.
  - Estrés térmico.
- ++ Latencia: 100 veces inferior (10-5 sg. vs. 10-3 sg.).
- + Ancho de banda: El doble (500 MB/sg. vs. 250 MB/sg.).
- + Más pequeño y robusto.
- + Menor consumo.
- - Sus celdas pueden reescribirse un número limitado de veces.
- - Precio medio más elevado (aprox. 0.1€/GB. vs. 0.05€/GB.).

-Fabricantes más populares: Kingston, Samsung, Toshiba y Crucial. En general, la mayoría de los fabricantes de DRAM.

3. Implementaciones del sistema de ficheros

3.1. La visión lógica del Sistema Operativo

-El controlador hardware y software del disco se encargan de transmitir al Sistema Operativo una visión que oculta casi todos los detalles de su circuitería.

-El **formateado** del **disco descompone** su **espacio útil** en una **serie continua** de **clusters direccionables** en **una sola dimensión** (LBA - *Logical Block Addressing*), para que sea **direccionable** de **forma similar** a como **vimos** para la **DRAM**.

-El **cluster** puede agrupar **varios sectores** del **disco**, siendo el **sector** la **unidad** de **trabajo** para el **controlador**. Cada **sector** tiene una **cabecera** con **metadatos**, su **área** de **datos** y un **campo final ECC** para la **corrección** de **errores**.

3.2. Organización del disco

-Un **disco** se divide en **particiones**, cada una de ellas **formateada** con un **sistema** de **ficheros**, que puede ser:

- Linux (ext2, ext3, ext4, …).
- UNIX (UFS - Unix File System).
- Windows: FAT12, FAT16, FAT32, NTFS (a partir de Windows NT - *NT File System*).
- MacOS: Tiene el suyo propio, HFS+, y además soporta FAT y lee NTFS.

-Cada **entidad** que **alberga** un **sistema** de **ficheros** (disco o partición) se **denomina volumen**. Estos **volúmenes** pueden **estructurarse** en **RAID** (*Redundant Array of Independent Disks*) para **mejorar rendimiento** (RAID 0) y **protección** (RAID 1): otros números son esquemas intermedios.

-Las **particiones** contienen **ficheros agrupados** en **directorios**.

3.3. Estructuras de datos en disco

-El **S.O.** habilita un **bloque** de **control** de **fichero** (FCB) para **gestionarlo** y **registrar** sus ***clusters*** en **disco**:

- i-nodos en UNIX.
- Master File Table en NTFS y FAT en sus precursores.

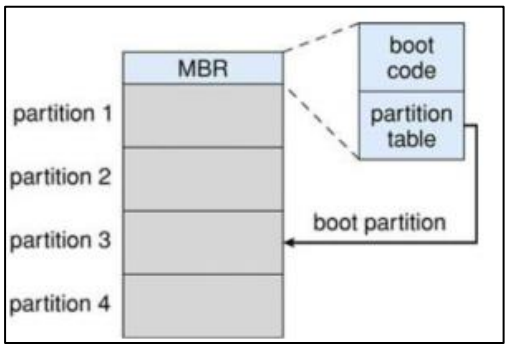

-También se **registran** los ***clusters* libres** para poder **asignarlos** a los **ficheros**.

-Para cada **volumen** de **disco** se habilita:

- Un **bloque** de **control** de **arranque**:
  - En el caso del PC se conoce como MBR (Master Boot Record). Ejemplos: LILO, GRUB.
  - A través de la tabla de particiones, lanza pequeños programas, los bloques de arranque de cada una de las particiones, para inicializar las mismas.
- Un **bloque** de **control** de **volumen**:

- En **UNIX** se llama **superbloque**, y en **NTFS**, forma parte del **Master File Table** (MFT).
- Contiene **metadatos**, como el **número** de **clusters**, su **tamaño**, el **espacio libre** en **disco** y **punteros** a los **FCB** de los **ficheros**.

3.4. Visión global del sistema de ficheros UNIX

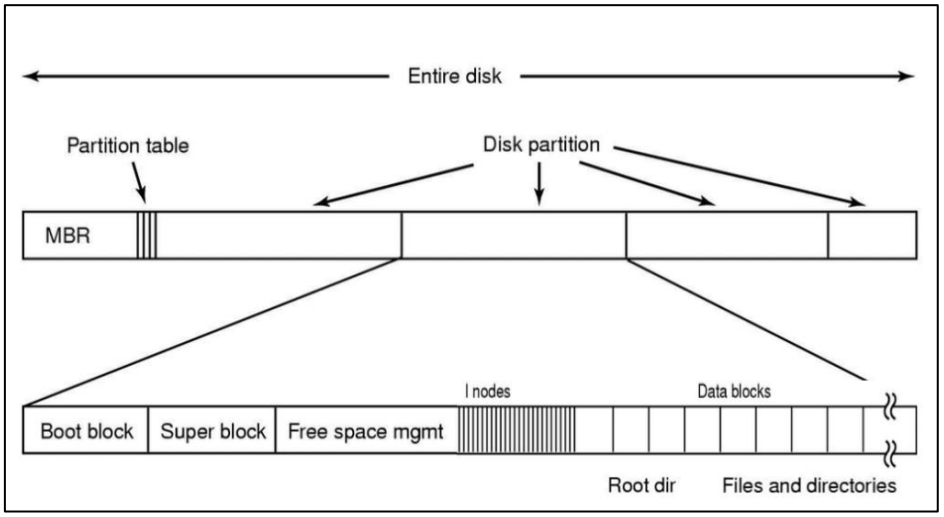

3.5. Estructuras de datos en memoria

-Cuando el **S.O.** monta un **disco** para usarlo, aloja en **DRAM** algunas **estructuras** de **datos** con un **doble fin**:

- Llevar una **gestión eficiente** de las **operaciones** en **disco**.
- **Mejorar** el **rendimiento utilizando** la **DRAM** como una **caché** (de ahí la obligación de **avisar** al **S.O**. para que lo **desmonte antes** de **desconectarlo** si no queremos tener inconsistencias en los datos).

-Estas **estructuras** de **datos comprenden**, entre otras:

- Un **tabla** que **registra** cada **volumen montado**.
- Una **caché** para los **clusters** más **recientemente solicitados**.
- **Tablas** que **registran** los **FCB** de todos los **ficheros abiertos**: una **tabla global** a **nivel** de **sistema** y **otra** para **cada proceso**.
- **Copias** de los **FCB** cuando se **leen/escriben** a **disco**.

4. Métodos de alojamiento

4.1. Concepto y estrategias

-El **alojamiento** de **ficheros** consiste en **registrar** los **clusters** que **pertenecen** a **cada** uno de **ellos**, de forma que se **pueda**:

- **Acceder aleatoriamente** a la **información** que **contienen**.
- **Gestionar** sus **operaciones básicas**: Creación, borrado, ampliación, …

-Existen **3 métodos** de **alojamiento sucesivamente** más **complejos**: **contiguos**, **enlazados** e **indexados**.

- Contiguos: Alojan los **clusters** de un **fichero** de forma **consecutiva** en el **espacio** de **disco**. Esto **impide** al **fichero crecer** tras su **creación** (o tener que realojarlo), lo que no es **nada realista**.
- Enlazados: Se han **utilizado** desde los **primeros PC** bajo **MS-DOS** y sus **sucesores** de **Microsoft** (hasta Windows NT), siendo el **ejemplo** más **extendido** las **FAT** (File Allocated Table).
- Indexados: **Utilizados** en **UNIX** desde sus **orígenes**.

4.2. Alojamiento enlazado

-Cada **fichero** es una **lista enlazada** de **bloques** de **disco** que se **dispersan** por el **espacio** de **almacenamiento**. Ejemplo:

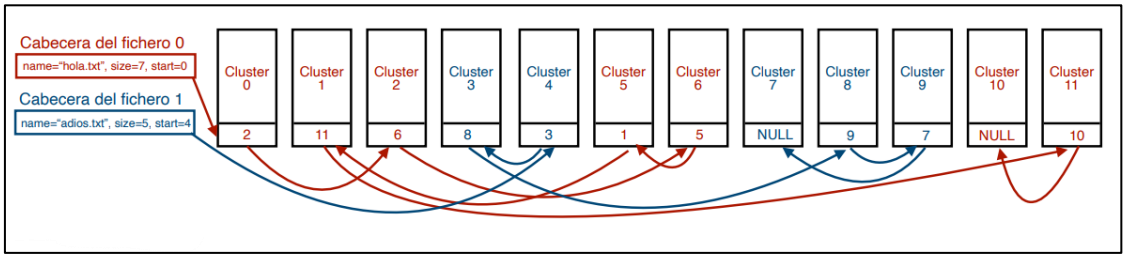

-**Ventajas**:

- Los **ficheros** pueden **crecer dinámicamente**.
- La **lista** de ***clusters*** **libres** puede **gestionarse** como un **fichero más**.

-**Inconvenientes**:

- El **acceso secuencial** requiere un **seguimiento** de la **cadena**, pero sobre todo, el **acceso aleatorio** es **muy ineficiente**.
- Es **poco fiable**: Si **falla** un **enlace**, se **pierde** el **resto** del **fichero**.

4.3. Ejemplo de alojamiento enlazado: FAT (*File Allocated Table*) de MS-DOS

- Los **enlaces no van** en los **clusters**, sino que se **agrupan** todos en la **FAT**, una **tabla** aparte que puede **alojarse** en **caché** para **agilizar consultas** y **actualizaciones**.

- Para el **ejemplo** anterior, la **FAT** sería:

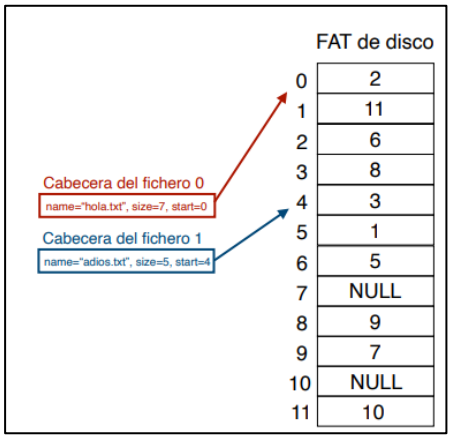

4.4. Versiones de FAT

- FAT12: La inicial de 1977 para **buses** de **direcciones** de **12 bits**.
  - Se **usó** para los **primeros discos flexibles**. Muy **obsoleta**.

- FAT16: La que empleó **MS-DOS** en 1987.
  - **Extendió** el **tamaño** del **cluster** a **32** y **64 Kbytes** para los **últimos S.O.** que lo **incorporaron** (Windows XP, 2000 y NT).

- FAT32: La **versión** en **uso actualmente**.
  - **Amplía** a **32 bits** la **dirección** de cada **cluster** para llegar a **Terabytes**.
  - En la **práctica**, **Microsoft** limitó a **28 bits** y **espacios** más **reducidos** por **limitaciones** de su **software**.

4.5. Alojamiento indexado

- Para cada **fichero** se **crea** una **tabla** de **punteros** a los ***clusters*** que **alojan** su **información** en **uso**.

- Ventajas:
  - El **acceso aleatorio** es muy **eficiente**.
  - El **fichero** crece **dinámicamente sin** padecer **fragmentación externa**.

- Inconvenientes:
  - La **longitud** de la **tabla define** el **máximo tamaño** del **fichero**.
  - Los **clusters** pueden estar **diseminados** por el **disco**, lo que **requiere** múltiples **posicionamientos** del **brazo**, con la consiguiente **ineficiencia**.

- Visión lógica:

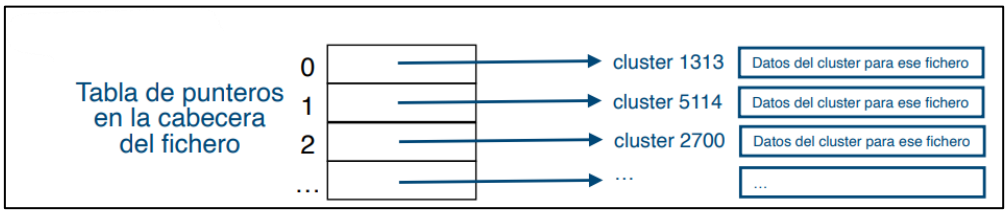

4.6. i-nodos en UNIX

- El **i-nodo** es la **cabecera** de un **fichero UNIX**. Utiliza una **tabla** de 10 punteros para el **acceso directo** a los **primeros *clusters***. A partir de ahí, 3 punteros de indexación múltiple son sucesivamente más lentos pero permiten abarcar más:
  - El puntero indirecto simple apunta a un *cluster* lleno de punteros.
  - El puntero indirecto doble (P.I.D.) apunta a un *cluster* lleno de P.I.S.
  - El puntero indirecto triple (P.I.T.) apunta a un *cluster* lleno de P.I.D.

- La **idea** es **similar** a la de las **tablas** de **páginas multinivel**.

- Lo **mejor** es **verlo** con un **ejemplo**: a partir de la versión 4.1 de UNIX BSD, se usó este sistema con:
  - Tamaño de *cluster* de 1 Kbyte.

- Punteros de 32 bits (4 bytes) para los *clusters*.
- Esto permite particiones de hasta 4 Terabytes (2^{32} *clusters* de 1 Kbyte cada uno).

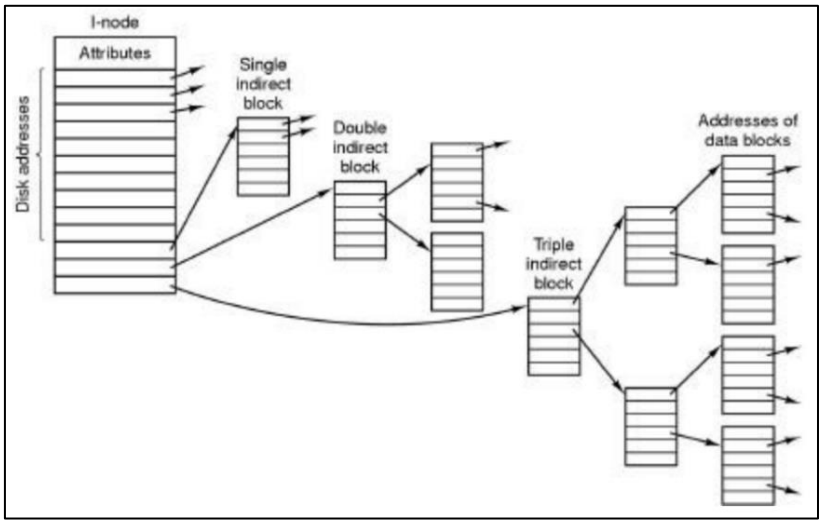

4.7. Caso estudio sobre el UNIX BSD 4.1

- Con los **10 punteros directos** podemos **acceder** a **ficheros** de hasta **10 Kbytes**, que es el **espacio** más **frecuente**.

- El **puntero indirecto simple** apunta a un ***cluster*** de **1 KB**, en el que caben **256 punteros** de **32 bits**, para **256 KB más**.

- El **puntero indirecto doble** apunta a un ***cluster*** en el que **caben 256 P.I.S.** de **32 bits**, para 256 * 256 KB = **64 MB**.

- El **puntero indirecto triple** apunta a un ***cluster*** que contiene **256 P.I.D. de 32 bits**, para 256 * 64 MB = **16 GB. adicionales**.

- En **total**, el **máximo tamaño** de **fichero** es de:
  - 16 GB + 64 MB + 266 KB.
- … dentro de una **partición máxima** que ya vimos de **4 TB.**

4.8. Información que se aloja en un i-nodo

Campo	Bytes	Descripción
Modo	2	Tipo de fichero, bits de protección, bits de config. de usuario y grupo.
N-links	2	Número de entradas de directorio apuntando a este i-nodo.
UID	2	ID del usuario propietario del fichero.
GID	2	ID del grupo propietario del fichero.
Size	4	Tamaño del fichero (en bytes).
Addr	39	13 punteros (10 directos, 1 indirecto simple, otro doble y otro triple).
Gen	1	Número de usos (se incrementa cada vez que el i-nodo se reutiliza).
A-time	4	Fecha y hora en que se accedió por última vez al fichero.
B-time	4	Fecha y hora de creación del fichero.
M-time	4	Fecha y hora en que fue modificado por última vez el fichero.
C-time	4	Fecha y hora en que el i-nodo se modificó por última vez.

5. Directorios

5.1. Concepto

- Los **directorios** son **carpetas** que **permiten organizar** los **ficheros**, agrupándolos según **cierta afinidad** establecida por el **usuario**. Ejemplos:

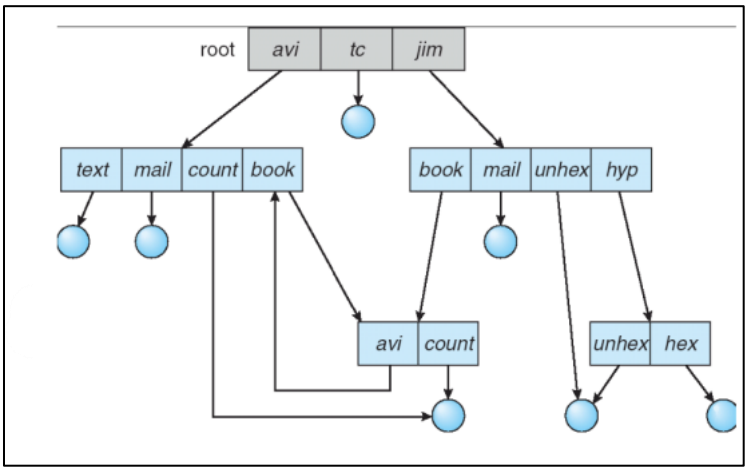

  - Un **directorio** para todos mis **programas Java**.
  - Un **directorio** para la **asignatura S.O.**

-Ventajas:

  - **Permite localizar** la **información** más **fácilmente**.
  - **Versatilidad**:
    - Un mismo fichero puede tener varias copias y nombres en distintas ubicaciones.
    - El mismo nombre puede ser usado por distintos usuarios para distintos ficheros.
    - Podemos establecer una jerarquía con directorios dentro de directorios

- Esto **último** se conoce como la **ruta** o **path** de un **fichero**.

5.2. Implementación

- Originalmente, se **gestionaban** como **ficheros especiales**, a los que se aplicaban sus **mismas llamadas** al **sistema**.

- Posteriormente, se **crearon nuevas llamadas** al **sistema** para ellos: **mkdir** (creación), **rmdir** (borrado), …

- Finalmente, se **añadieron** los **enlaces físicos** y **simbólicos**:

  - Un **enlace físico (*hard*)** permite establecer **rutas alternativas** para un **fichero** desde **otros directorios**. Se usa para ello el **comando ln**.
    - Se **pueden crear** muchos **enlaces físicos**, pero siempre dentro de una **partición**.
    - Si **borramos** un **fichero**, sigue **existiendo** para el **resto** de **enlaces físicos**.
  - Un **enlace simbólico (*soft*)** sólo es un **atajo** para **acceder** al **fichero**.
    - Se usa para ello el **comando ln -s**. A **diferencia** del **enlace físico**, esta **opción -s** se puede usar para un **directorio** o para un **fichero** en **otro PC** vía **NFS**.
    - Si **borramos** el **fichero**, todos sus **enlaces simbólicos** quedan **inservibles**.

5.3. Estructuras de datos

- Cada **directorio organiza** en una **tabla** sus **archivos**, donde hay una **fila** por **fichero**.

- En las **FAT** de **Microsoft**, dicha **fila contiene** el **nombre** y los **atributos**.

- En los **S.O. UNIX**, la fila **contiene** el **nombre** y un **puntero** al **i-nodo** del **fichero**, donde **estarán** los **atributos**.

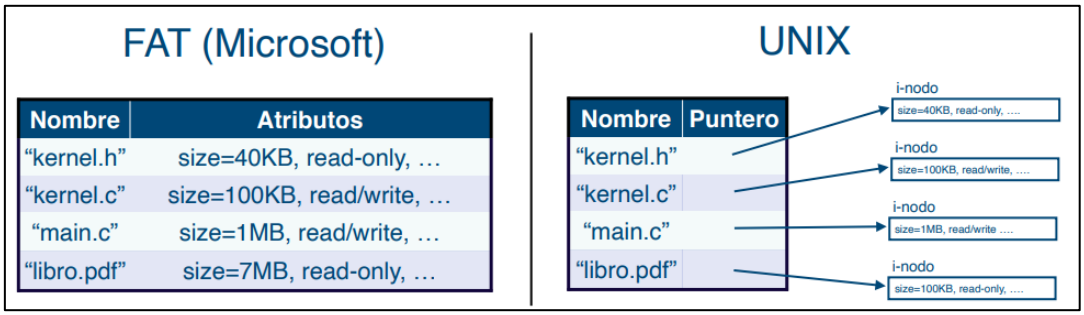

6. Otros aspectos

6.1. Gestión del espacio libre

- Idea 1: Lo más **simple** es **habilitar** un **mapa** de **bits**, con un **bit** por cada **cluster**, donde: **0=libre** / 1**=ocupado**.

  - **Espacio total ocupado**: para un disco de 1 Terabyte con clusters de 4 Kbytes, el mapa de bits ocuparía 256 Mbits, esto es, 32 Mbytes.
  - Su **principal inconveniente** es la **lentitud**, a no ser que sacrifiquemos estos 32 Mbytes en caché para alojar el mapa de bits íntegramente.

- Idea 2: Usar una **lista enlazada** de **clusters** libres, tal y como hace la **FAT** para **enlazar** los **clusters** de cada **fichero**.

  - **No** se **desperdicia espacio**, pero sigue **siendo lento** y **cuesta tener** el **espacio libre** consecutivamente en **disco**.

- Idea 3: Usar una **tabla** de **acceso indexado** a cada **cluster**.

  - Es el **esquema** más **rápido**, a **costa** de **sacrificar espacio**.

6.2. Elección del tamaño del cluster

- El **tamaño** del **cluster** tiene la **misma incidencia** que el **tamaño** de la **página** en el **sistema** de **memoria**:

  - Si es **pequeño**, se **aprovecha mejor** el **espacio**, pero **no** se **amortiza** la **latencia** del **disco** y la **gestión** del **alojamiento ocupa** más **espacio**.
  - Si es **grande**, se **desperdicia más espacio** por **fragmentación interna** pero se **aprovecha mejor** el **ancho** de **banda** en el **acceso** a los **datos**.

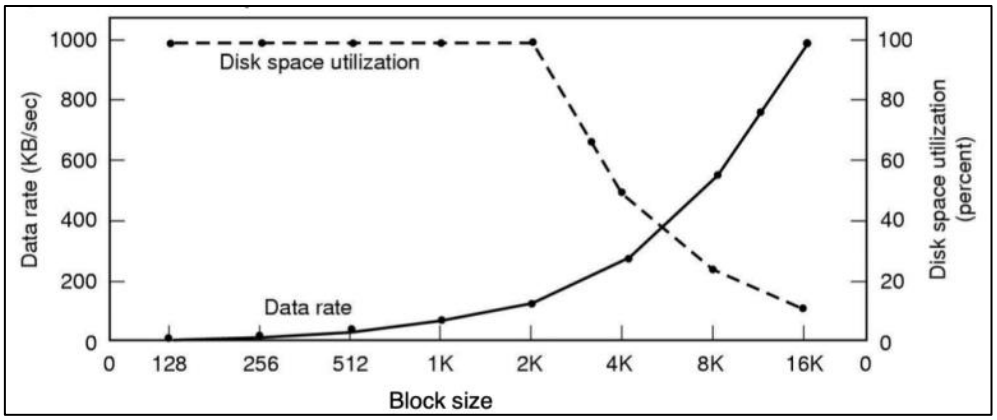

6.3. Mejoras de rendimiento y consistencia

- El **disco incluye** una **memoria DRAM** de unos **64 Mbytes** que **actúa** de **caché** para el **sistema** de **almacenamiento**, **reteniendo** los ***clusters*** que **más** se **referencian**.

  - Los ***clusters*** **compiten** por la **caché** de igual forma que las **páginas** por los **marcos** en **memoria virtual** (localidad, reemplazo LRU, …).

- **Organizar** el **disco** en **grupos** de **cilindros**, tratando de **albergar** un **i-nodo** y sus **clusters** de **datos** en **pistas vecinas**.

  - **Reduce** el **tiempo** de **posicionamiento** del **brazo** del **disco** (**seek**).

- **Journaling**: Anotar cada **operación antes** de **realizarla** en el **disco**, lo que **mantiene** una **copia** de **seguridad**.

  - Si **falla** el **sistema** de **ficheros**, puede **reconstruirse** el **disco**.
  - Esta **idea** se **incorporó** a partir del **sistema** de **ficheros** "**ext3**" de **Linux**, que **posteriormente** también sería **adoptada** por el **NTFS** de **Windows**.

7. Bibliografía

- *Operating Systems Concepts*, 8th Edition de A. Silberschatz, G. Gagne, P.B. Galvin, publicado por Wiley en 2008.

  - Chapter 10: File System Interface (para nuestras secciones I y II)
  - Chapter 11: File System Implementation (para las secs. III, IV, V y VI)